

Hogyan változtatja meg a mesterséges intelligencia a csillagászatot?

Hanyecz Ottó

Polaris Csillagvizsgáló

Budapest

2020. október 27.

Tartalom

- 1 Big Data és mesterséges intelligencia
 - Big Data
 - A mesterséges intelligencia fogalma
 - Gépi tanulás
 - Neurális hálók
- 2 A gépi tanulás alkalmazásai a csillagászatban
 - A heliocentrikus modell "újrafelfedezése"
 - Fizikus MI
 - Exobolygók detektálása
 - A 25. napciklus előrejelzése
- 3 Összefoglalás
- 4 Ajánlott irodalom

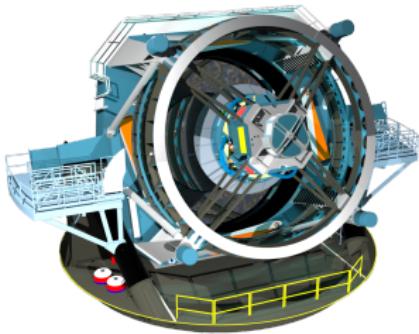
Mi az a Big Data?

Large Synoptic Survey Telescope

- ▶ minden éjszaka feltérképezi a fél eget, ami
- ▶ 15 terabajt (TB) adatot termel.
- ▶ 10 év alatt 50 petabajt (1 PB = 1000 TB) nyers adat keletkezik,
- ▶ ami feldolgozva több, mint 100 PB lesz.

CERN

- ▶ 2017. december: 1 PB adat közzététele ([CERN News](#))
- ▶ Összesen ~1,5 PB



Fotó: LSST



Fotó: CERN/CMS

Mi az a Big Data?

Mi az a Big Data?

Az az adatmennyiség, amit a hagyományos adatbáziskezelők már nem tudnak kezelni, mert túl nagy, gyorsan fel kell dolgozni és sok formában létezhet.

A Big Data 4V-je:

- ▶ Volume (Mennyiség)
- ▶ Velocity (Sebesség)
- ▶ Variety (Sokféleség)
- ▶ Veracity (Bizonytalanság)

Big Data - problémák és a megoldás

Problémák:

- ▶ Nincs ember, aki lépést tud tartani ekkora adatmennyiséggel
- ▶ A "hagyományos" adatfeldolgozó algoritmusok túl lassúak
- ▶ Változó minőségű adatok
- ▶ Adatvizualizáció problémás lehet ($d > 3D$)

Megoldás: mesterséges intelligencia

- ▶ Minimális emberi beavatkozás kell
- ▶ Jó alak- és mintafelismerők
- ▶ Gyorsak és pontosak (de ehhez dolgozni kell)
- ▶ Jól kidolgozott eszközök: *tensorflow*, *keras*, *pandas*, *scikit-learn*, *numpy*, *pytorch*...

Gyenge MI vs. Erős MI

Gyenge MI

- ▶ Konkrét problémát old meg, de azt nagyon jól
- ▶ Egy konkrét algoritmussal
- ▶ Pl: Amazon Alexa, cicás képek azonosítása, ajánló rendszerek



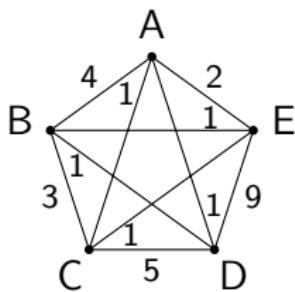
Erős MI

- ▶ Legalább olyan jól végzi el a munkát, mint az ember
- ▶ Általános algoritmus - *mindenre* jó lesz
- ▶ Még a közelében sem járunk

Miről ismerhető fel egy szoftverben az MI?

- A megoldandó feladat: nehéz

Utazó Ügynök Probléma

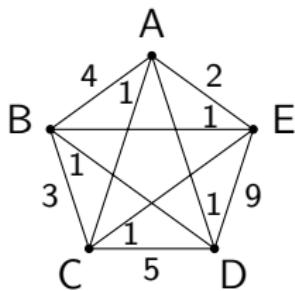


| Csúcs | Utak száma |
|-------|------------------------|
| 5 | 24 |
| 10 | 362880 |
| 25 | $\sim 6 \cdot 10^{23}$ |

Miről ismerhető fel egy szoftverben az MI?

- ▶ A megoldandó feladat: nehéz

Utazó Ügynök Probléma



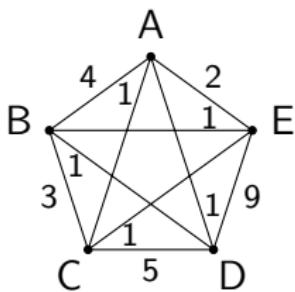
| Csúcs | Utak száma |
|-------|------------------------|
| 5 | 24 |
| 10 | 362880 |
| 25 | $\sim 6 \cdot 10^{23}$ |

- ▶ A szoftver viselkedése: intelligens
 - ▶ Automatikus következtetés
 - ▶ Megszerzett ismeret tárolása

Miről ismerhető fel egy szoftverben az MI?

- A megoldandó feladat: nehéz

Utazó Ügynök Probléma



| Csúcs | Utak száma |
|-------|------------------------|
| 5 | 24 |
| 10 | 362880 |
| 25 | $\sim 6 \cdot 10^{23}$ |

- A szoftver viselkedése: intelligens
 - Automatikus következtetés
 - Megszerzett ismeret tárolása
- Felhasznált eszközök: sajátosak
 - Heurisztikával megerősített hatékony algoritmusok
 - Gépi tanulás módszerei

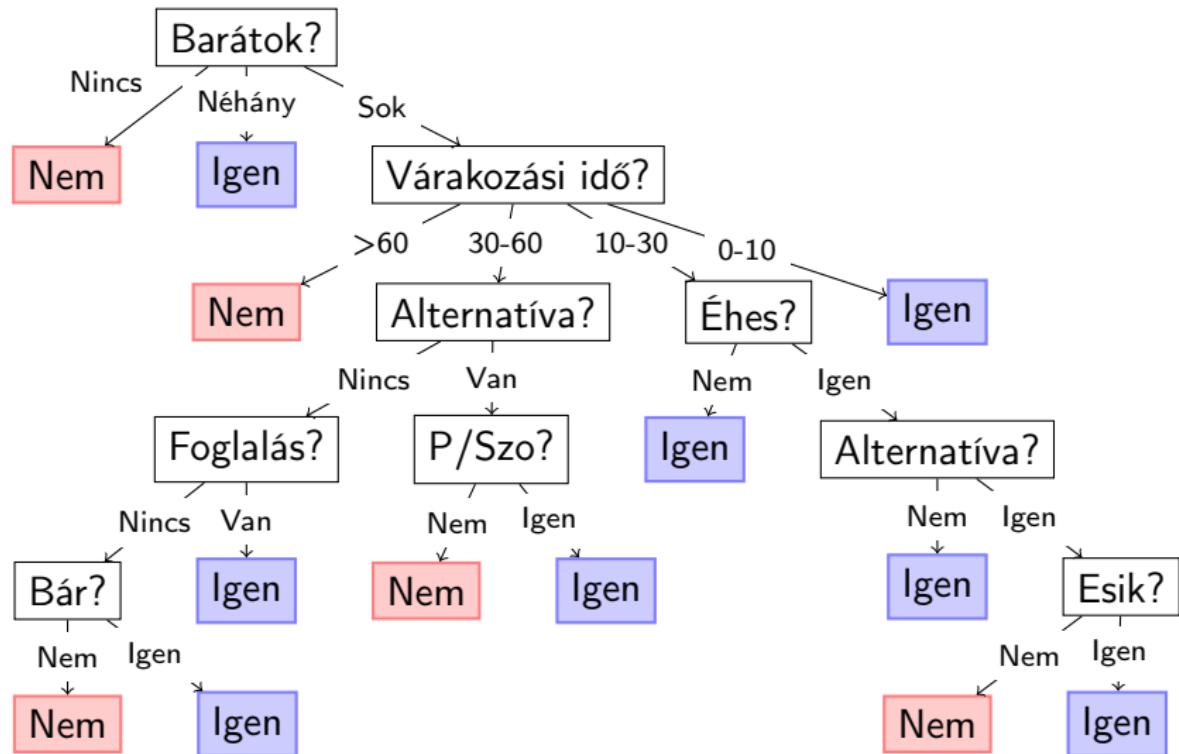
Gépi tanulás

- ▶ Egy algoritmus tanul, ha egy feladat megoldása során olyan változások következnek be a működésében, hogy később ugyanazt a feladatot jobban (eredmény, hatékonyság) képes megoldani, mint korábban
- ▶ Konkrét utasítások nélkül
- ▶ Tanító mintákra van szükség, teszt mintával ellenőrizzük az algoritmust
- ▶ Felügyelt, felügyelet nélküli, megerősítéses tanulás

Felügyelt tanulás

- ▶ **Tanító minta:** a minták elvárt kimenete ismert
- ▶ **Teszt mintával** ellenőrizzük a modell általánosító képességét
- ▶ Két nagy csoport: osztályozás és regresszió (előrejelzés)
- ▶ Példák: kép és spam felismerése, időjárás-előrejelzés, népességnövekedés

Felügyelt tanulás - Várunk-e az asztalra?



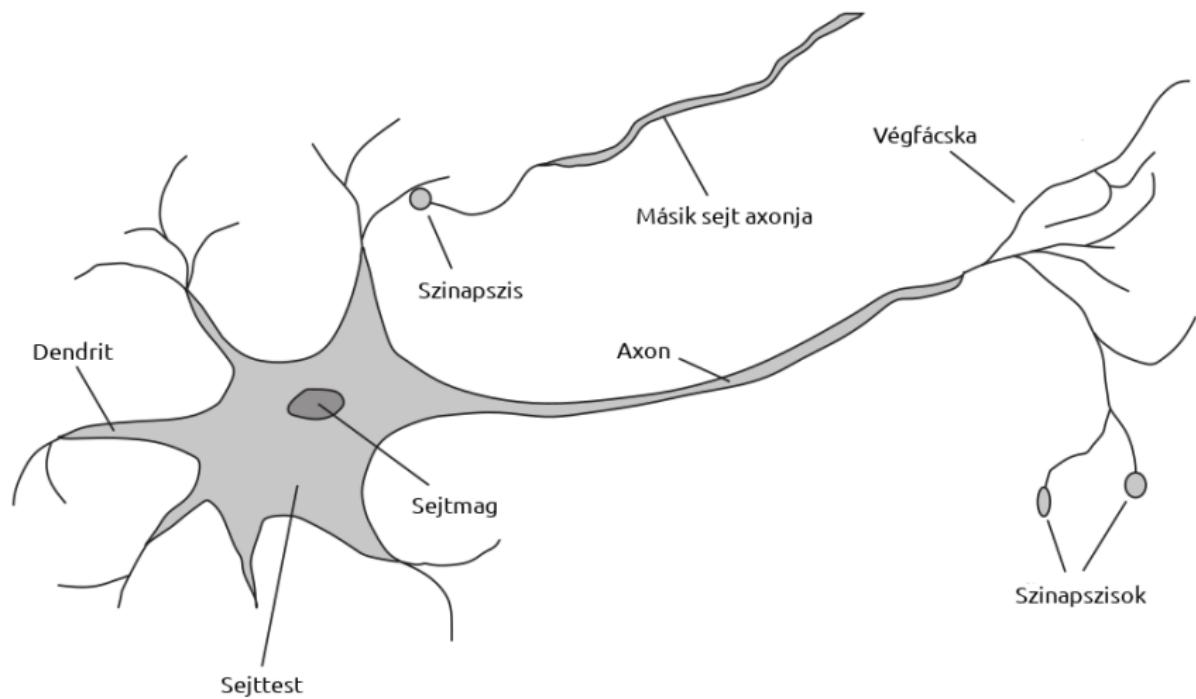
Nemfelügyelt tanulás

- ▶ Tanító minta bemenő adatokkal, nincs meg az elvárt kimenet
- ▶ Kérdés: van-e valami struktúra?
- ▶ Példa: [Google News](#)

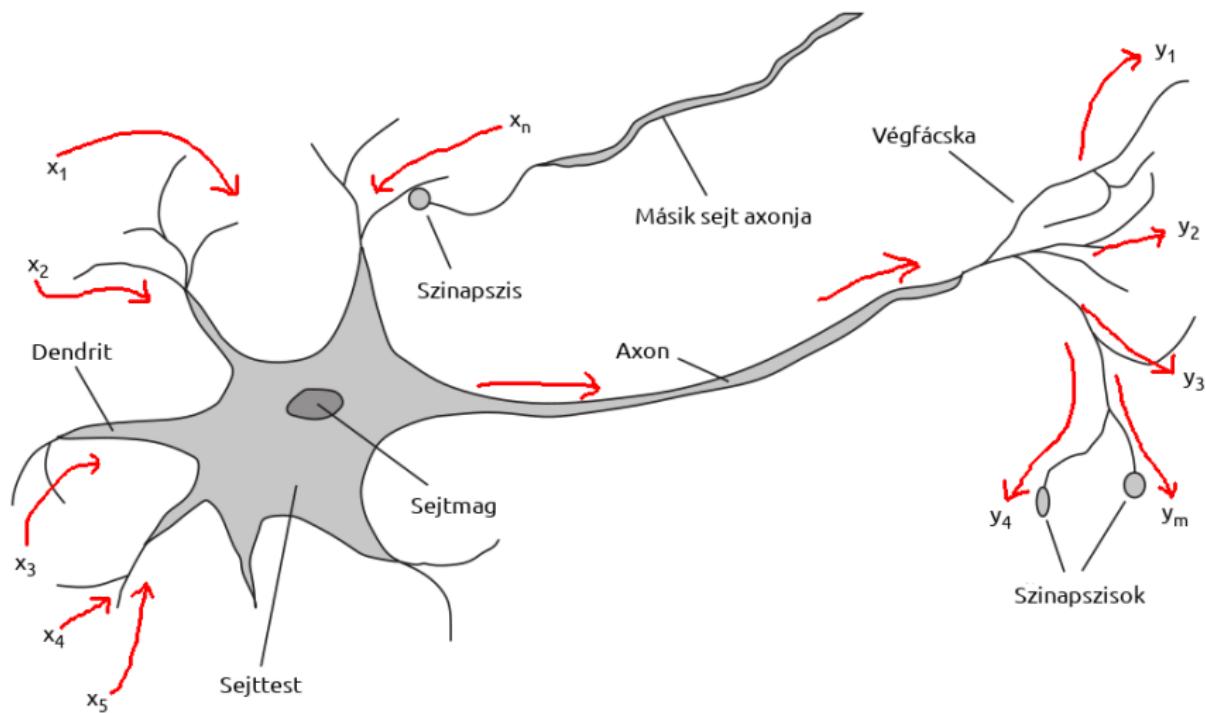
Megerősítéses tanulás

- ▶ Példa:
 - ▶ [AlphaGo](#) (2015 október, 5-0)
 - ▶ [AI Learns to Park](#) (Youtube)
 - ▶ [Two AI Fight for the same parking spot](#) (Youtube)
- ▶ Nincs visszajelzés, hogy mi a jó vagy rossz
- ▶ Az algoritmus megtanulja, hogy *melyik a jó lépés*
- ▶ Mi lehet megerősítés? Mikor kap az algoritmus megerősítést?

Neurális hálók

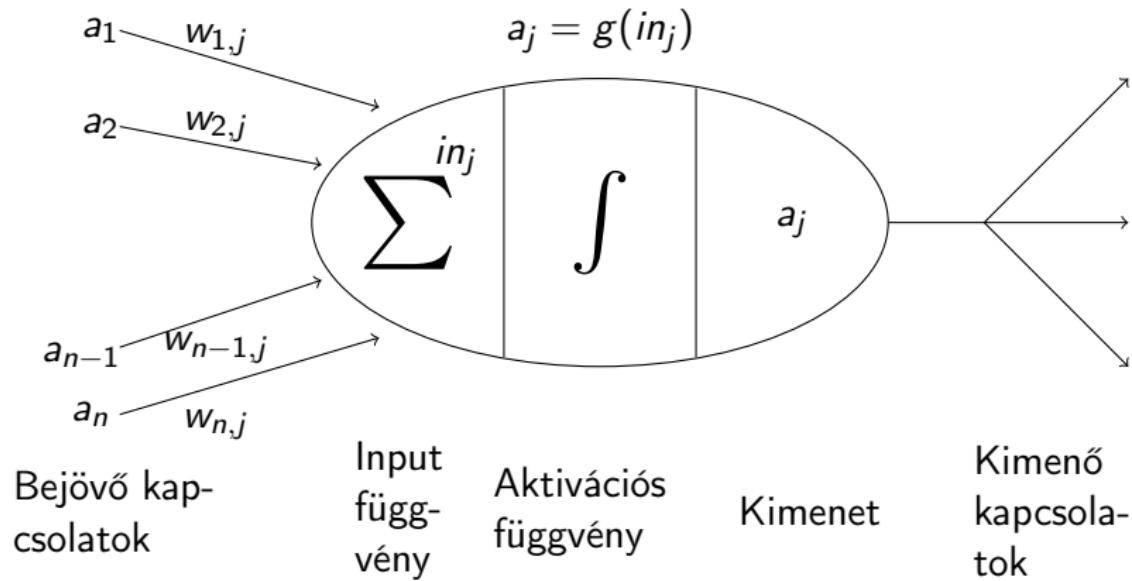


Neurális hálók

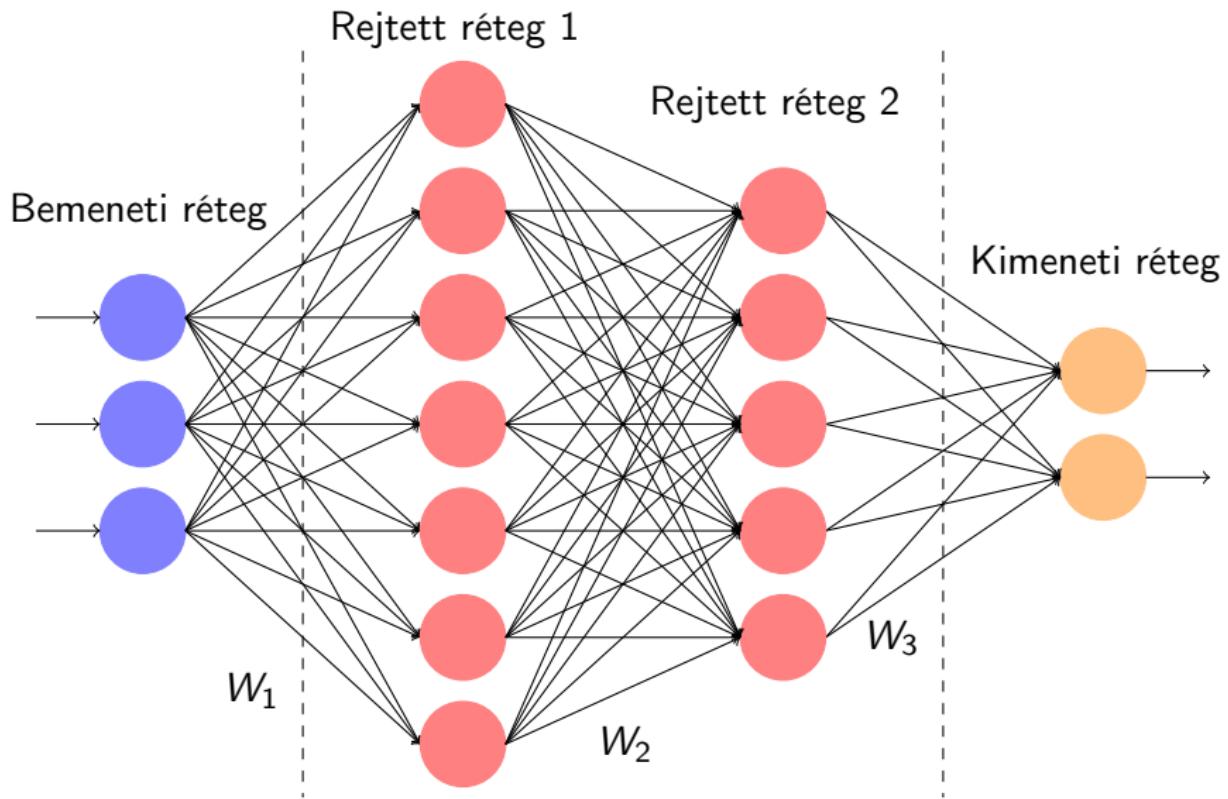


Neurális hálók

Első matematikai leírás: McCulloch and Pitts (1943)



Neurális hálók - Feed-forward háló



Neurális hálók

Problémák:

- ▶ Nincs általános háló
- ▶ Próbálgatással kell a jó hálót beállítani (vagy ügyesen megsejteni)
- ▶ Feed-forward hálók nem foglalkoznak a bemenet térbeli felépítésével

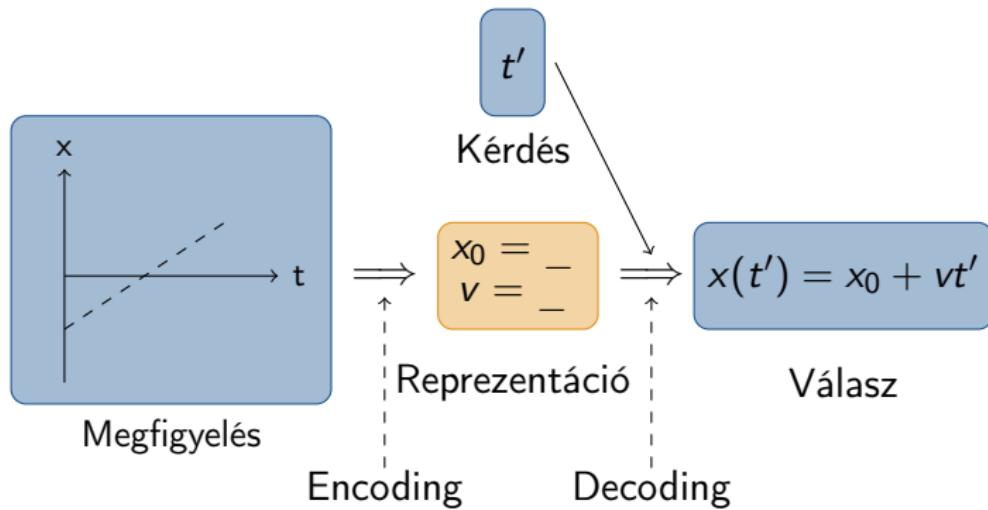
Megoldás:

- ▶ Mély neurális hálók
- ▶ Konvolúciós neurális hálók
- ▶ Generatív modellek
- ▶ ...és még sok más

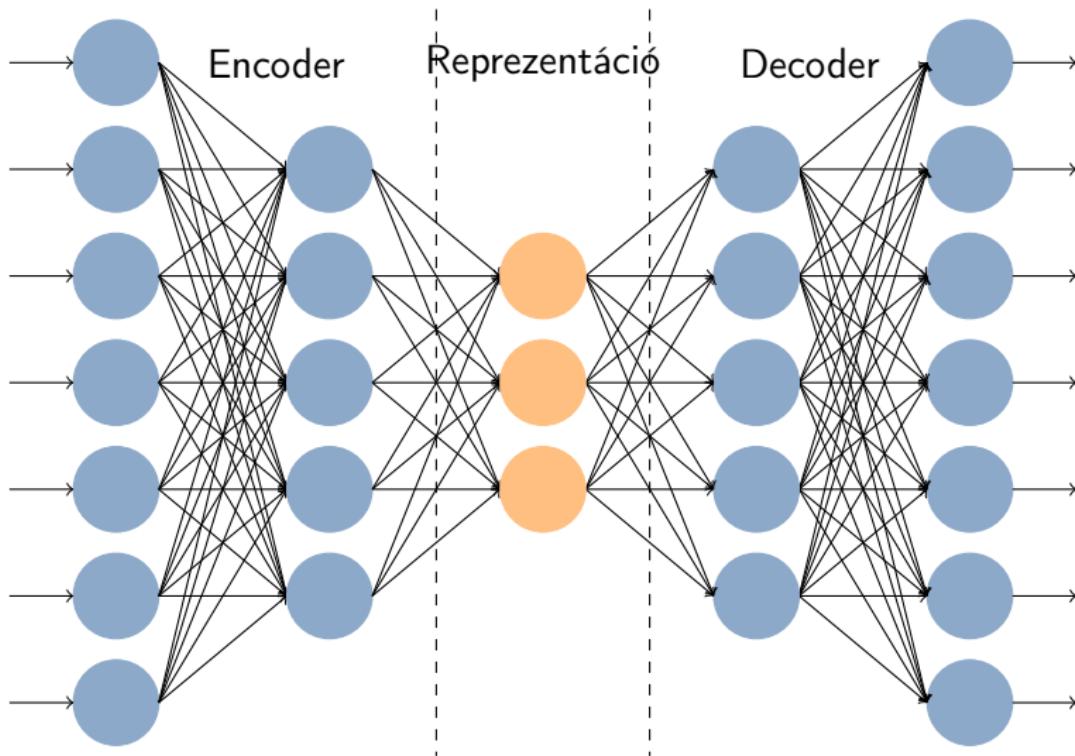
Heliocentrikus modell "újrafelfedezése"

Raban Iten et al. [Discovering physical concepts with neural networks](#)
(2020)

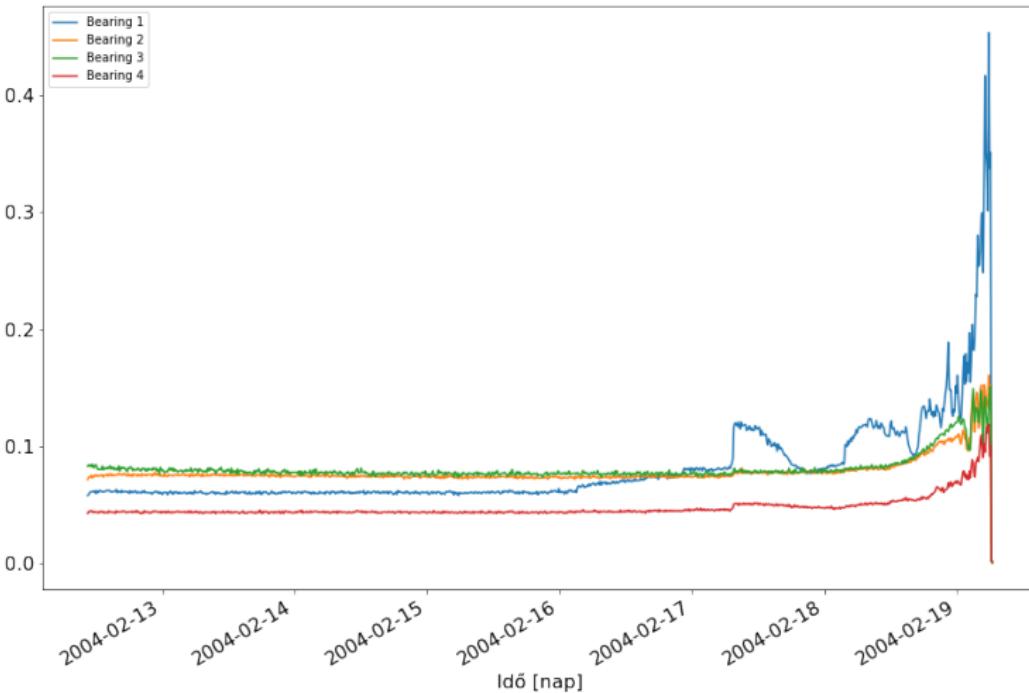
Fizikai modellek tanulása 1.



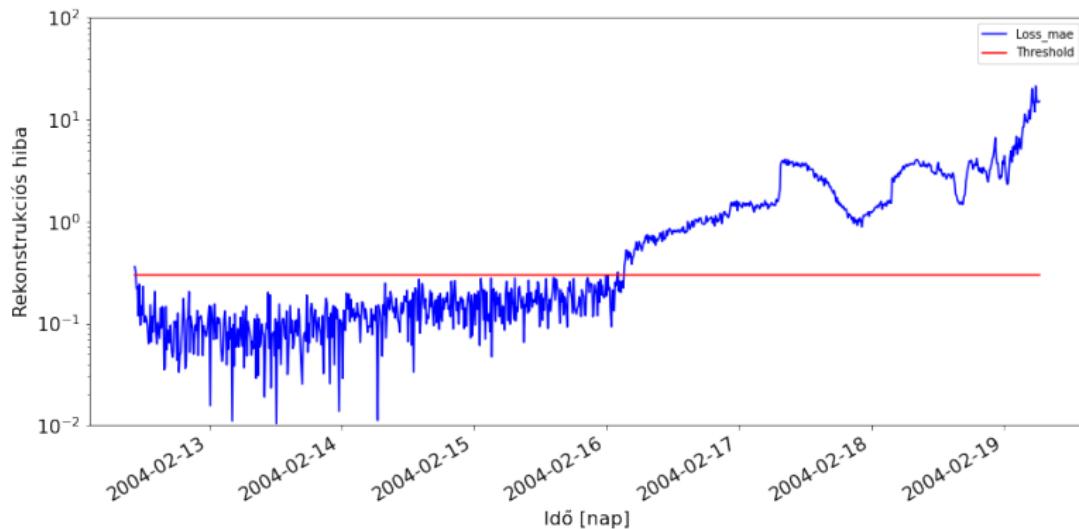
Autoencoder



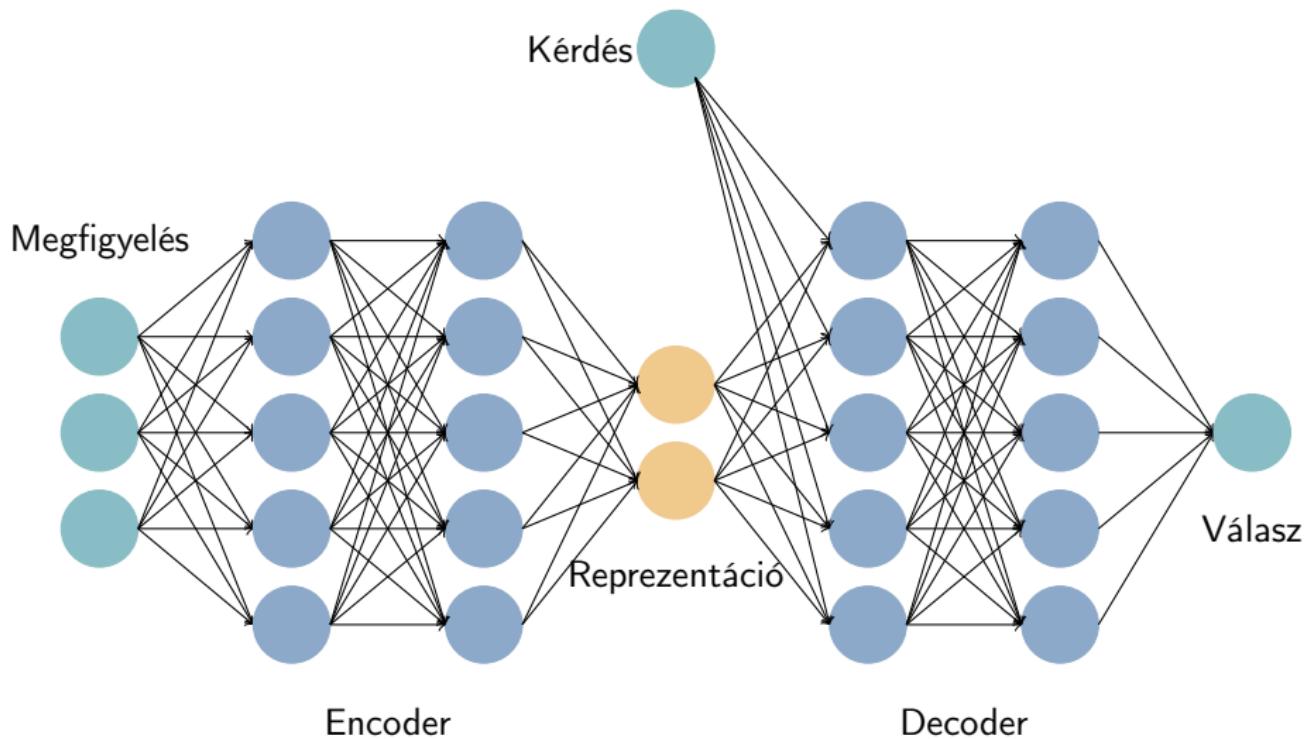
Autoencoder - Kerék meghibásodás



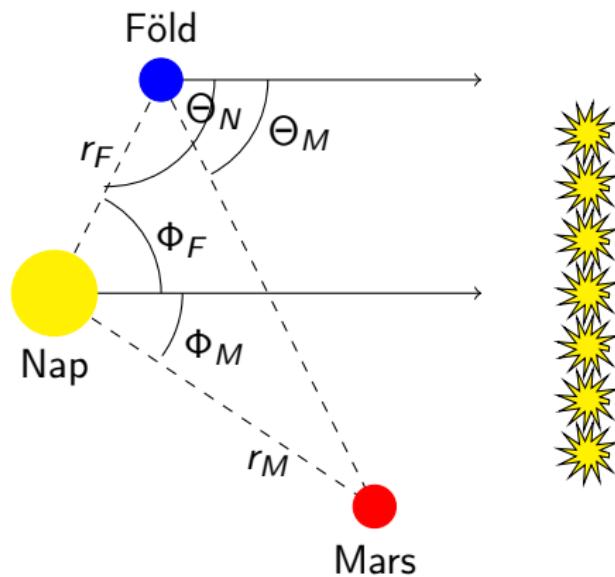
Autoencoder - Kerék meghibásodás



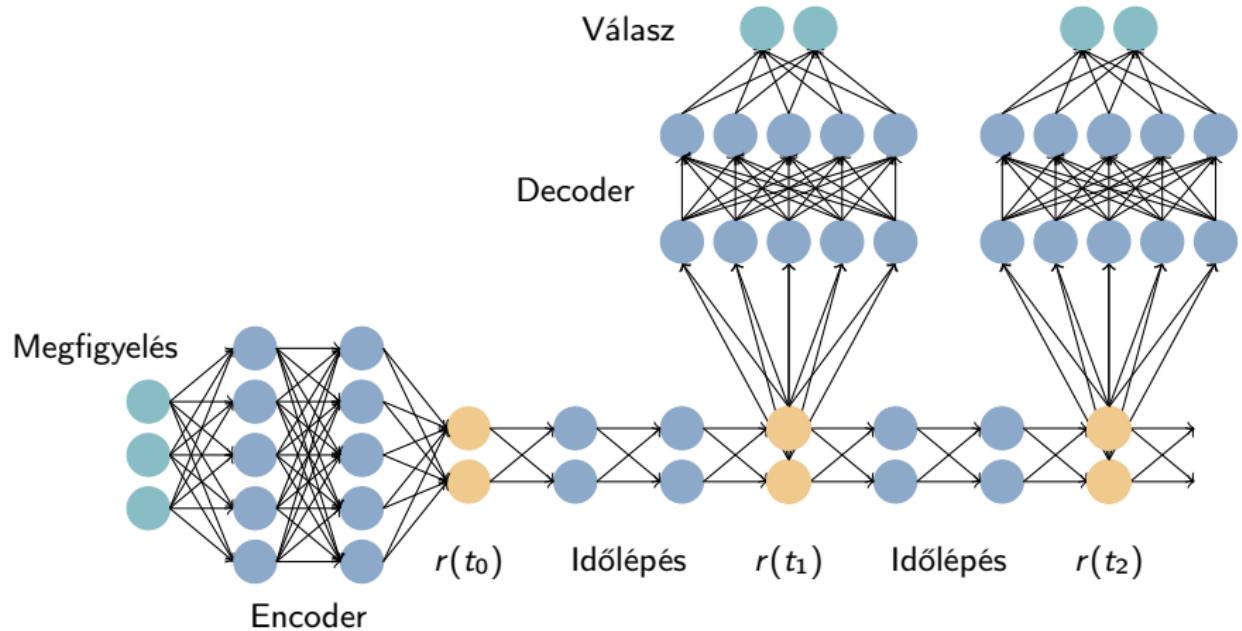
Fizikai modellek tanulása 2.



Heliocentrikus modell "újrafelfedezése"



Heliocentrikus modell "újrafelfedezése"



Heliocentrikus modell "újrafelfedezése"

Probléma: $\Theta_M(t)$ és $\Theta_N(t)$ előrejelzése a Földről nézve, ha ismert $\Theta_M(t_0)$ és $\Theta_N(t_0)$.

Fizikai modell: A bolygók körpályán keringenek a Nap körül egyenletes sebességgel (adatgenerálás miatt).

Megfigyelés: $(\Theta_M(t_0), \Theta_N(t_0))$ párosok (ez a neurális háló bemente)

Kérdés: Implicit

Válasz: Szögmérések sorozata $(\Theta_M(t_1), \Theta_N(t_1)), \dots, (\Theta_M(t_n), \Theta_N(t_n))$

Főbb eredmények:

- ▶ Φ_F és Φ_M szögek tárolása ahogy a Naptól látszódik
- ▶ 0.4%-os hibával becsüli a szögeket

Fizikus MI

Eredeti cikk: [Toward an AI Physicist for Unsupervised Learning](#)

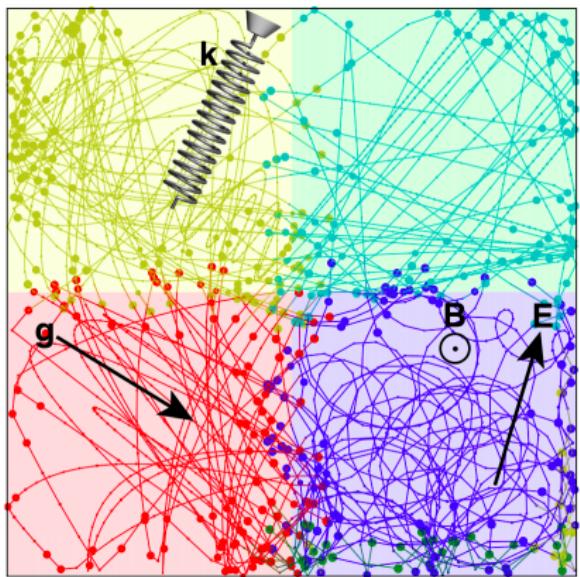
Miért jobb az ember?

- ▶ Az adatok más forrásból jönnek → általánosítási problémák
- ▶ Nagy modellek bonyolultak

Megoldás: Egyesével megtanulni az egyszerű modelleket és rendszerezni
Módszerek:

- ▶ Oszd meg és uralkodj: modell illesztése az adat egy részére
- ▶ Occam borotvája: legjobban illeszkedő modell kiválasztása
- ▶ Egyesítés: megtanult modellekből egy "mester elmélet" tanulása
- ▶ Élethosszig tartó tanulás: a tanult modelleket megjegyzi, később alkalmazza

Fizikus MI



Négy rész

- ▶ Harmonikus potenciál (sárga)
- ▶ Gravitációs mező (piros)
- ▶ Elektromágneses mező (lila)
- ▶ Rugalmas ütközés (cián)

Input: labda helyzete

Cél: határok azonosítása és a mozgás leírása

Pontok mérete: az előrejelzés hibája

Fizikus MI

Nehézség:

- ▶ Könnyű problémákat tud megoldani
- ▶ Felügyelt tanulással osztályozási problémává válik a feladat → előrejelzés egyszerűen megoldható
- ▶ Valóság nem osztályozott: határokat a mozgással együtt kell megtanulni
- ▶ Előrejelzési hiba *nagyon* lecsökkent
- ▶ Kaotikus rendszerekre is működik ugyanilyen hibával

Általánosíthatóság:

- ▶ A négy paradigma a lényeg, nem a konkrét implementáció
- ▶ Analógia: Turing-gép (univerzális számítógép, játékproblémákat old meg hatékonyan)

Exobolygók detektálása a Kepler-80 és Kepler-90 rendszerekben

Shallue, Christopher J.; Vanderburg, Andrew

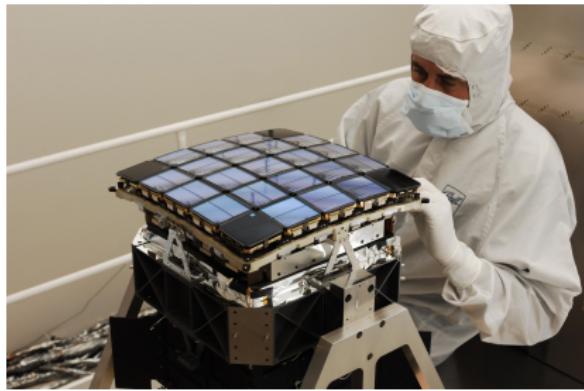
Identifying Exoplanets with Deep Learning: A Five-planet Resonant Chain around Kepler-80 and an Eighth Planet around Kepler-90.

The Astronomical Journal, Volume 155, Issue 2, article id. 94, 21 pp.
(2018)

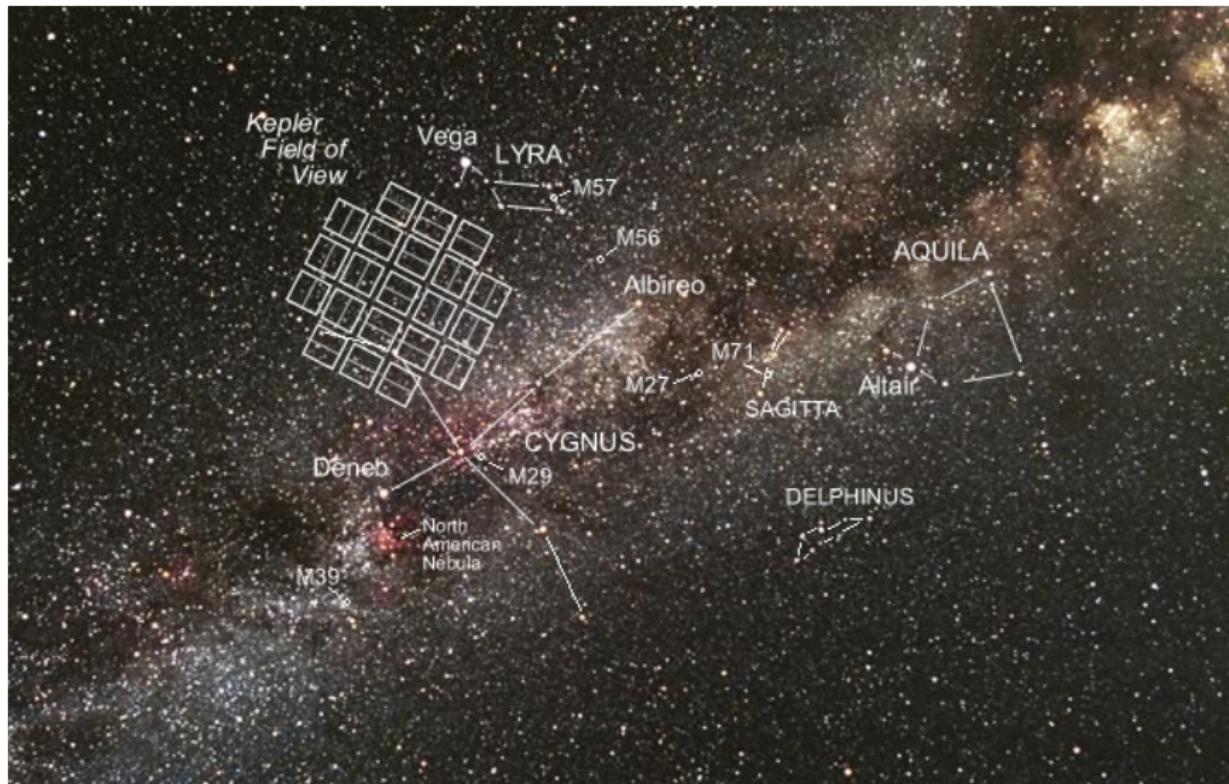
Kepler



- ▶ NASA Discovery Program
- ▶ 2009.03.07. Cape Canaveral
- ▶ First light: 2009.04.08.
- ▶ 95 cm Schmidt távcső
- ▶ 42 db 2200x1024 CCD

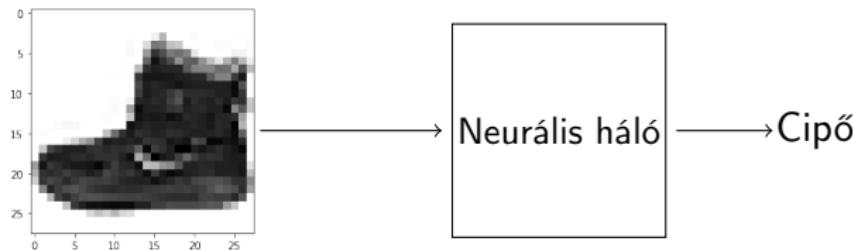


Kepler látómező



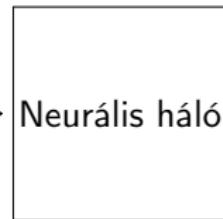
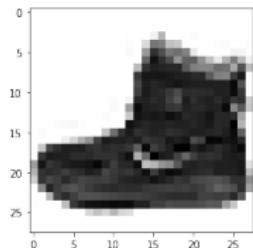
Neurális hálók

- ▶ Neurális hálókkal osztályozás példa: [Ruhák \(TensorFlow\)](#)

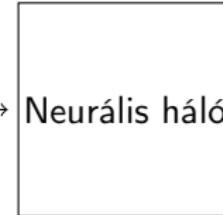


Neurális hálók

- ▶ Neurális hálókkal osztályozás példa: [Ruhák \(TensorFlow\)](#)



Cipő



???

Konvolúciós neurális hálók

- ▶ Ötlet 1: szűrjünk a képen, mielőtt tanítunk

Értékek

| | | |
|-----|-----|-----|
| 0 | 64 | 128 |
| 48 | 192 | 144 |
| 142 | 226 | 168 |

Szűrő definíció

| | | |
|-----|-----|------|
| -1 | 0 | -2 |
| 0.5 | 4.5 | -1.5 |
| 1.5 | 2 | -3 |

192 új értéke:

$$(-1 * 0) + (0 * 64) + (-2 * 128) + (0.5 * 48) + (4.5 * 192) + (-1.5 * 144) + \\ (1.5 * 42) + (2 * 226) + (-3 * 168)$$

Konvolúciós neurális hálók

Sobel szűrők

Függőleges vonalak

| | | |
|----|---|---|
| -1 | 0 | 1 |
| -2 | 0 | 2 |
| -1 | 0 | 1 |

Vízszintes vonalak

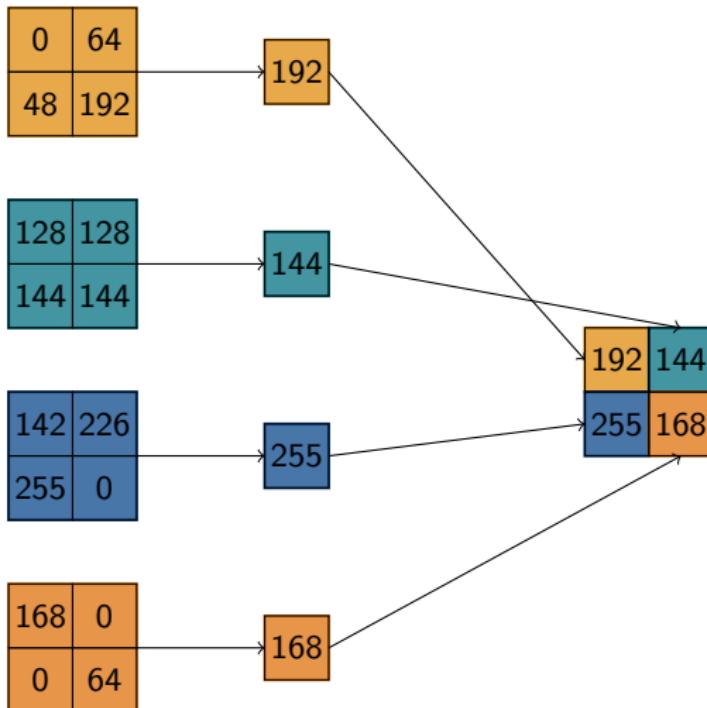
| | | |
|----|----|----|
| -1 | -2 | -1 |
| 0 | 0 | 0 |
| -1 | 2 | 1 |

Konvolúciós neurális hálók

- Ötlet 2: Pooling: pixeleket csoportosít és tovább szűr

Maxpooling 2x2:

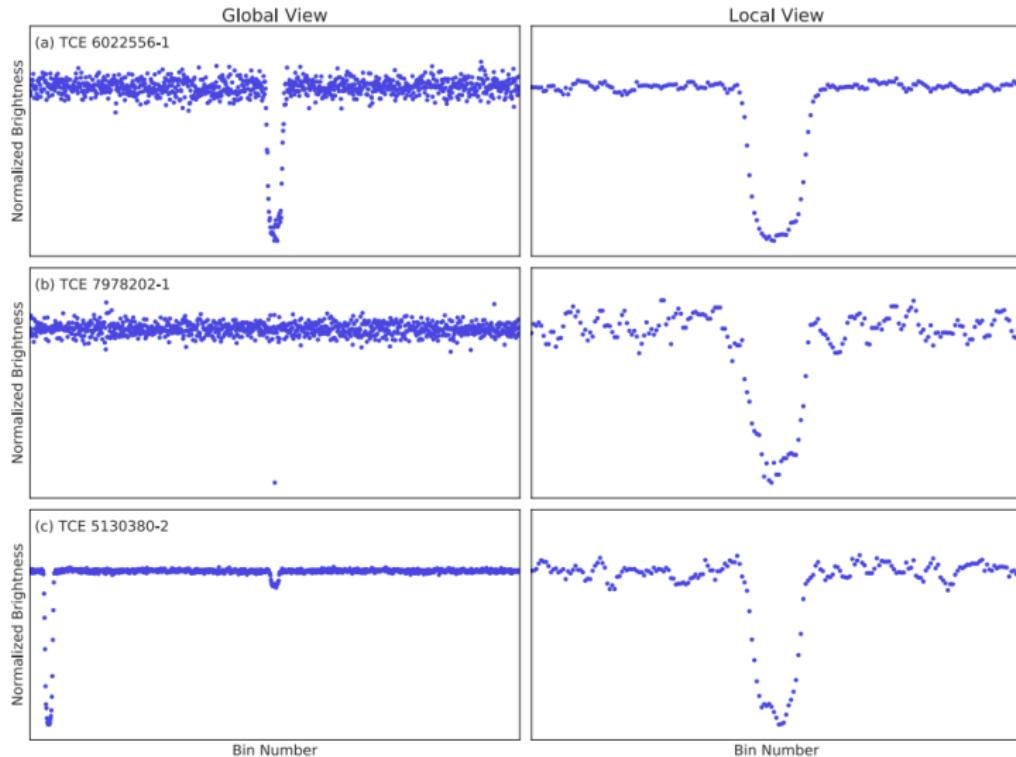
| | | | |
|-----|-----|-----|-----|
| 0 | 64 | 128 | 128 |
| 48 | 192 | 144 | 144 |
| 142 | 226 | 168 | 0 |
| 255 | 0 | 0 | 64 |



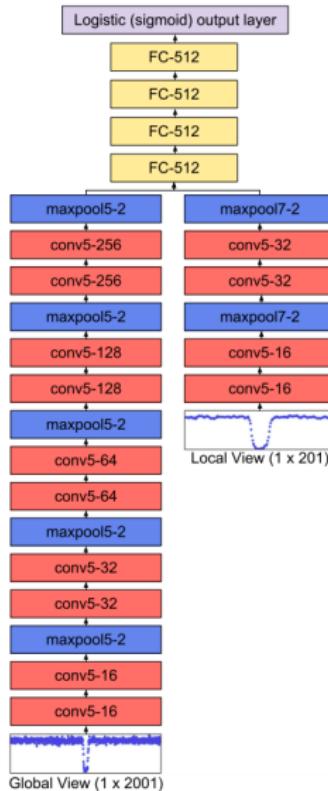
Konvolúciós neurális hálók

- ▶ Számfelismerő
- ▶ Konvolúciós neurális hálók interaktív vizualizálása

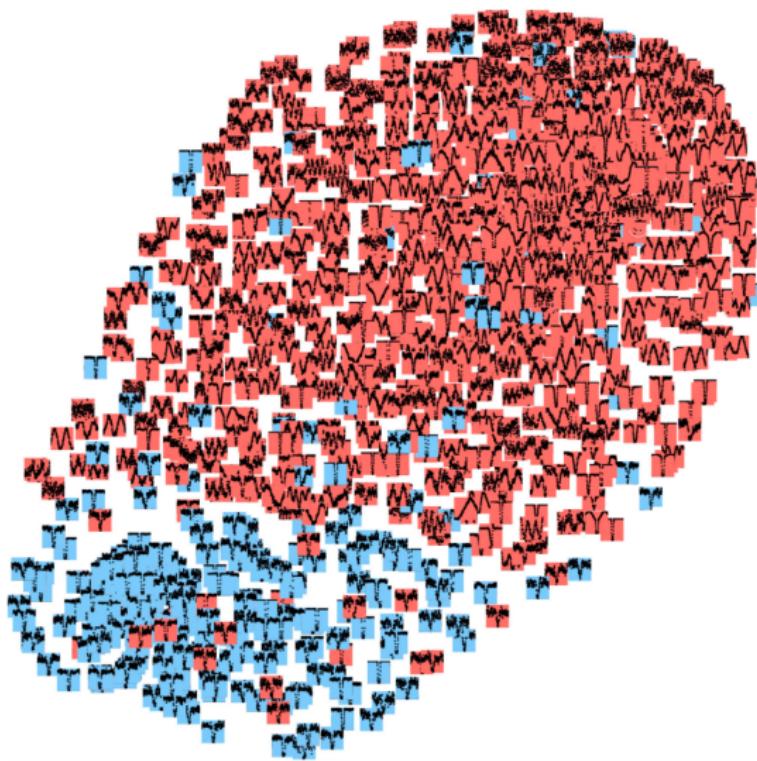
A Kepler-80 g és Kepler-90 i esete



A Kepler-80 g és Kepler-90 i esete



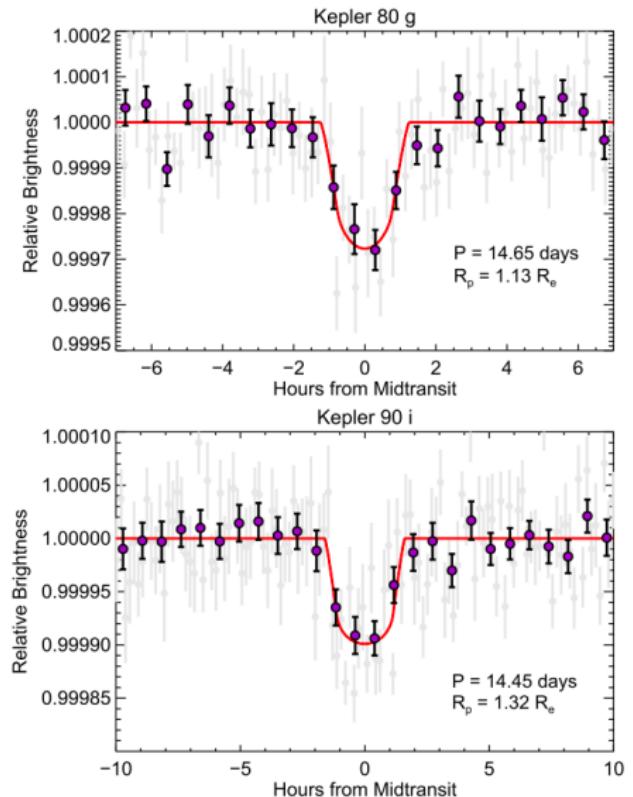
A Kepler-80 g és Kepler-90 i esete



A Kepler-80 g és Kepler-90 i esete

- ▶ 670 többes rendszer jelölt
- ▶ 157 jelölt eldobása: 30 percnél rövidebb fedés, nincs három fedés a teljes fénygörbében
- ▶ 513 marad
- ▶ ebből 30-nak 50%-nál nagyobb az esélye, hogy bolygó
- ▶ 9-nek 80%-nál nagyobb az esélye
- ▶ 4-nek 90%-nál nagyobb az esélye
- ▶ 1 spektroszkópiai kettős
- ▶ 1-nél műszeres effektusok zavarnak
- ▶ 2 bolygó

A Kepler-80 g és Kepler-90 i esete

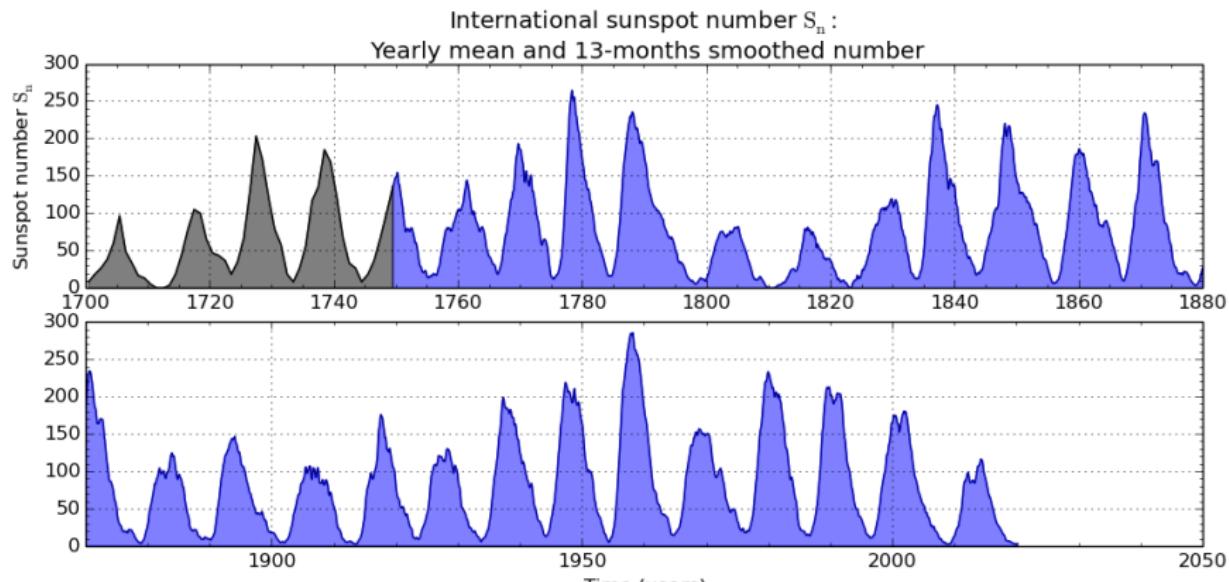


A 25. napciklus előrejelzése

Benson, B., Pan, W.D., Prasad, A. et al.

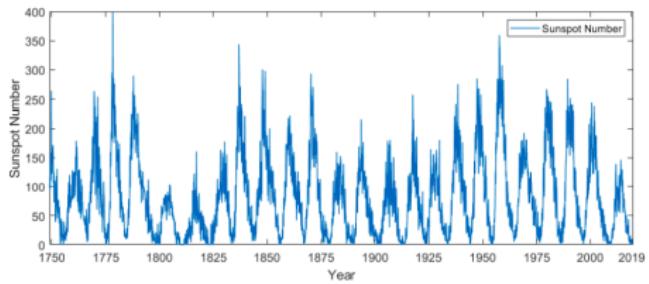
Forecasting Solar Cycle 25 Using Deep Neural Networks.
Sol Phys 295, 65 (2020)

Napciklus



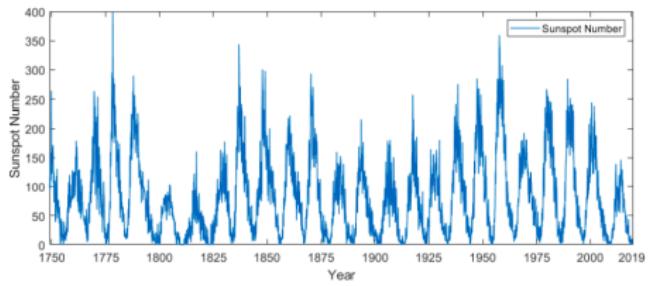
Előrejelzés mozgó átlaggal

- Minimális ablak: 2 ciklus (= 1 mágneses ciklus), de:

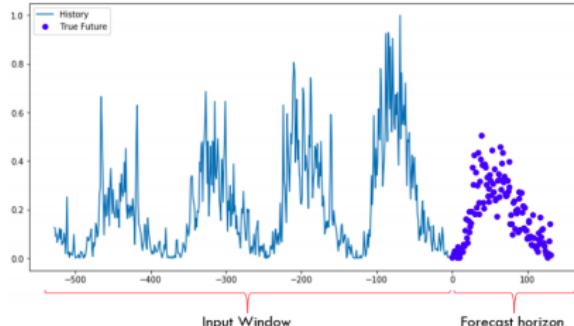


Előrejelzés mozgó átlaggal

- Minimális ablak: 2 ciklus (= 1 mágneses ciklus), de:



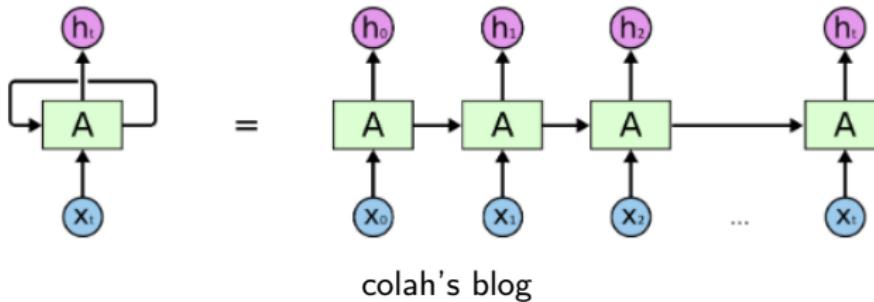
- Pontosabb előrejelzés: 4 ciklus hosszú ablak, egy ciklus hosszú előrejelzés, de:



Long Short Term Memory (LSTM) hálózatok

Understanding LSTM Networks (colah's blog)

Recurrent Neural Network (RNN):

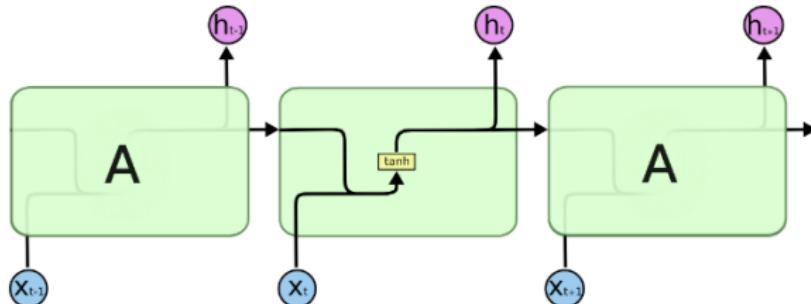


- ▶ Képes régi dolgokra "visszaemlékezni"
- ▶ Gyakorlatban nem, csak a rövidtávú dolgokra ("rövidtávú memóriája van")

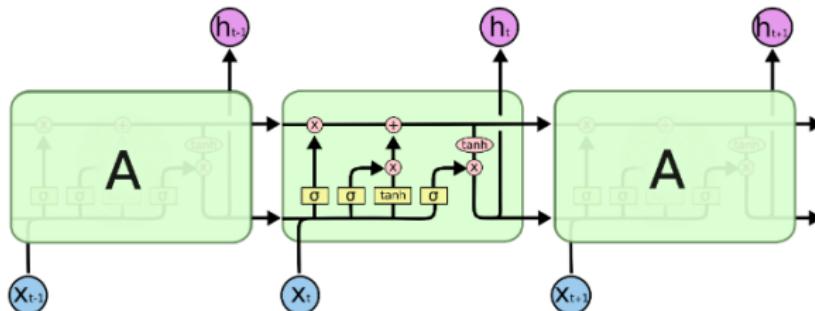
Long Short Term Memory (LSTM) hálózatok

Hochreiter & Schmidhuber (1997)

RRN modul:

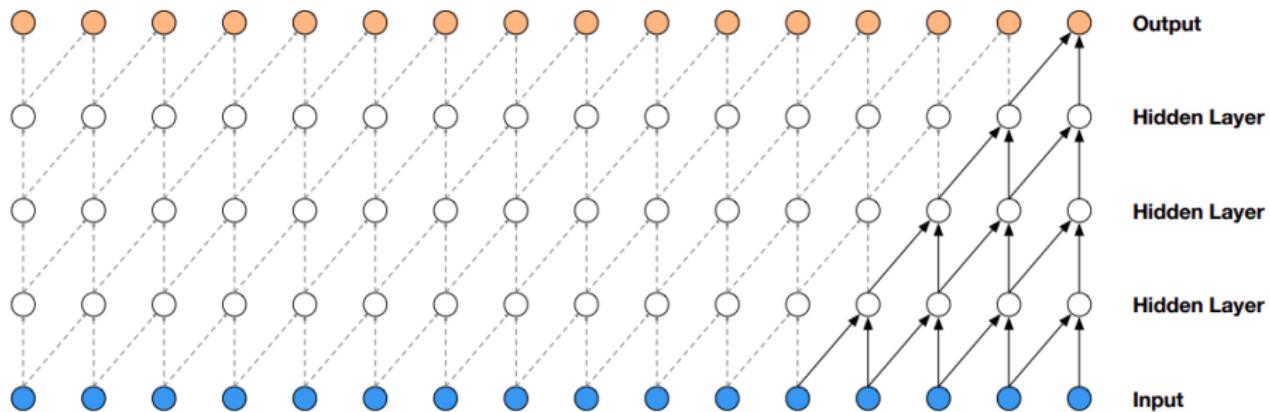


LSTM modul:



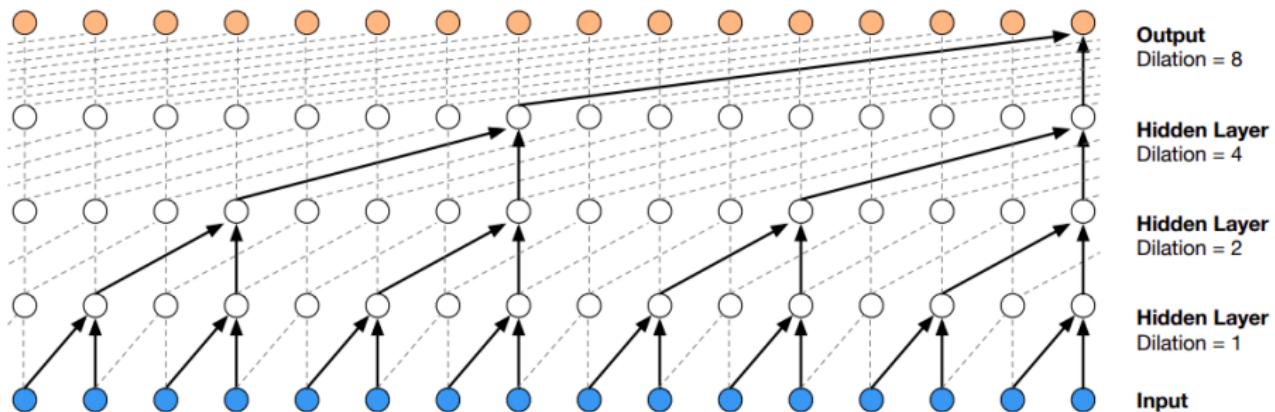
WaveNet

WaveNet - generatív modell hang generáláshoz

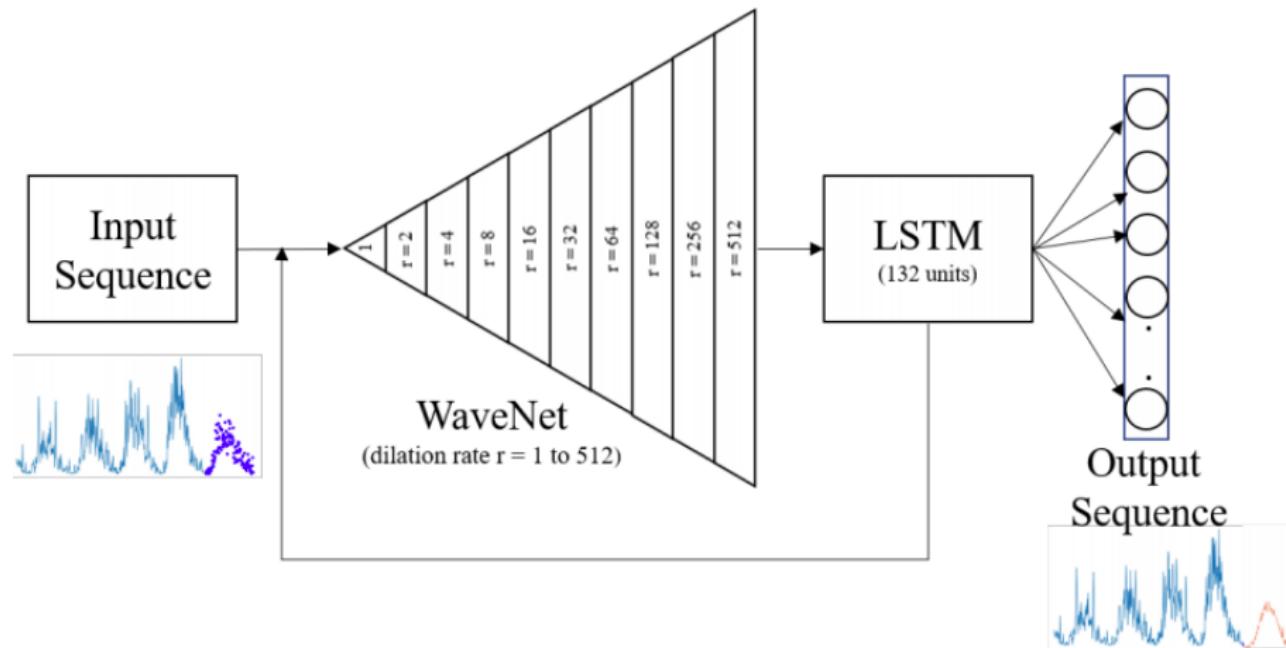


WaveNet

WaveNet - generatív modell hang generáláshoz



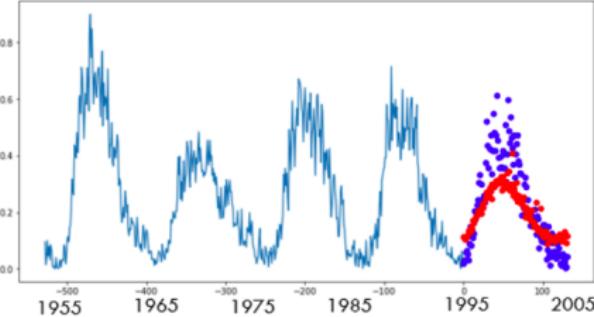
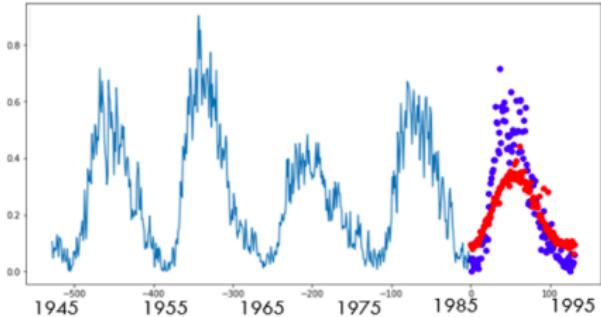
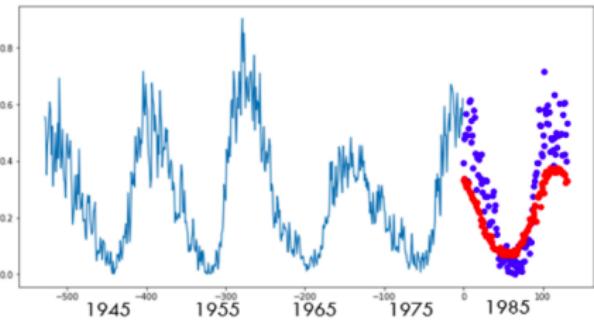
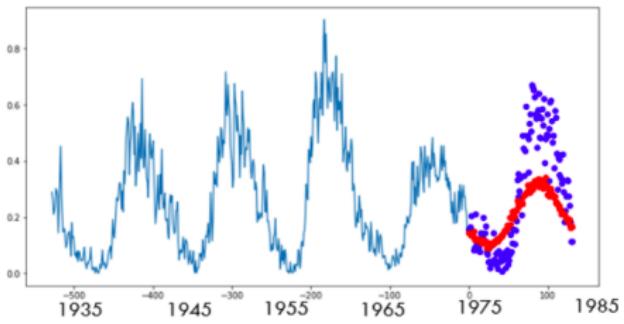
Az alkalmazott modell



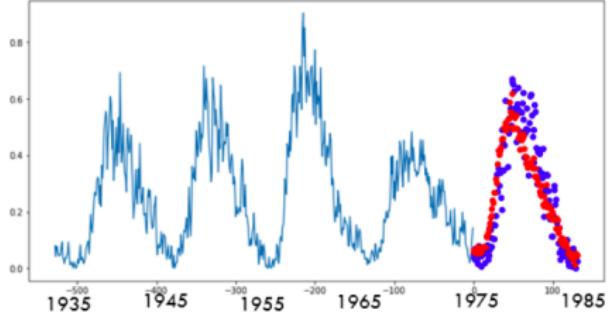
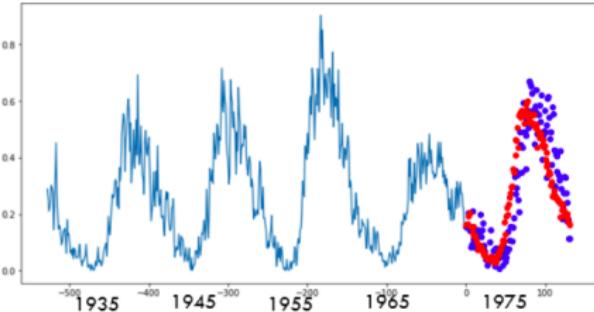
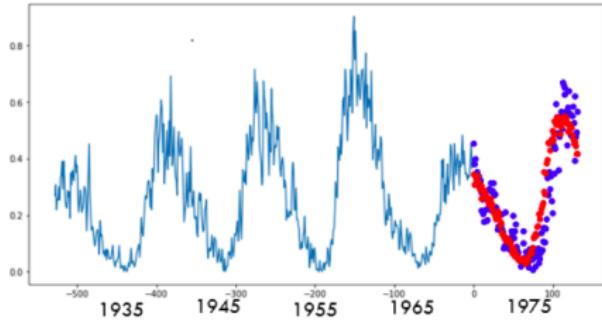
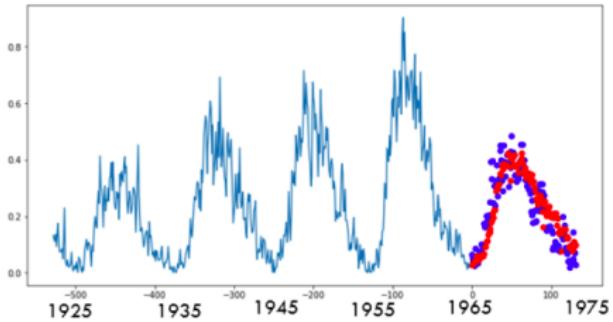
Miért?

- ▶ Klasszikus előrejelző módszerek lineáris összefüggést és ismert eloszlást feltételeznek
- ▶ LSTM nem feltételez semmit a rövid- és hosszútávú változásról
- ▶ Bonyolult, nemlineáris rendszerek is modellezhetők
- ▶ Generatív modellekkel tovább erősíthető (pl. WaveNet)

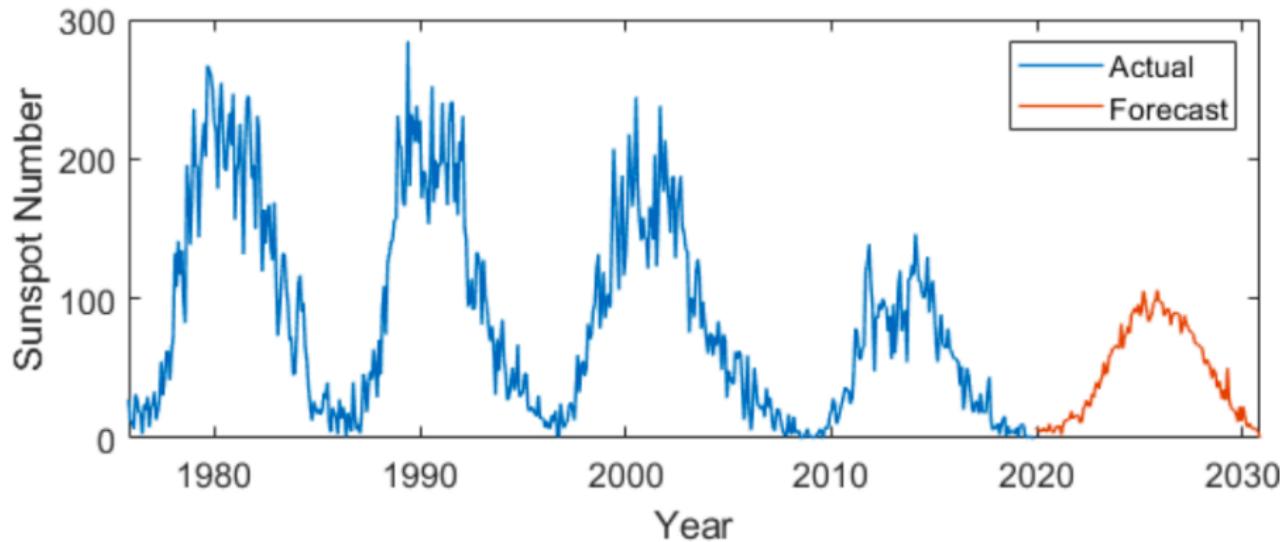
Két modell összehasonlítása - Két LSTM



Két modell összehasonlítása - WaveNet + LSTM



Az előrejelzés



- ▶ Napfoltszám max: 106 ± 19.75
- ▶ Maximum: 2025 március

Összefoglalás

- ▶ Tanulási paradigmák: felügyelt, felügyelet nélküli, megerősítéses
- ▶ Neurális hálók és felépítésük
- ▶ Különböző alkalmazási területek:
 - ▶ képfeldolgozás (Kepler-80 és Kepler-90)
 - ▶ napciklus előrejelzés
 - ▶ heliocentrikus modell
- ▶ ... és még nagyon sok

Az előadás anyaga elérhető [GitHub](#)-on

Ajánlott irodalom

Cikkek:

- ▶ Physicist's Journeys Through the AI World
- ▶ Explainable Machine Learning for Scientific Insights and Discoveries
- ▶ Machine learning & artificial intelligence in the quantum domain
- ▶ Representation Learning: A Review and New Perspectives

Könyvek:

- ▶ Stuart Russell, Peter Norvig: *Artificial Intelligence - A Modern Approach*

Videók:

- ▶ Machine Learning (Coursera)